Predicción de suscripción a una campaña de marketing bancario

Trabajo Práctico Final · Ciencia de Datos (I5521) · Ingeniería Industrial

Noviembre de 2026

1. Introducción y objetivos

Las campañas de marketing telefónico tienen un costo por contacto y tasas de conversión bajas. Un banco solicitó predecir qué clientes se suscribirán a una campaña, para priorizar a quién llamar. El objetivo es construir un modelo de *aprendizaje supervisado* de clasificación binaria que estime, **antes de llamar**, la probabilidad de suscripción de cada cliente, y evaluar si un método de reducción de la dimensionalidad (PCA) mantiene o mejora su desempeño. Como criterio de negocio se asume que perder a un cliente que se habría suscrito (falso negativo) es más costoso que realizar una llamada sin resultado (falso positivo).

2. Descripción del dataset

El conjunto de datos está basado en el *Bank Marketing Dataset* de Moro, Cortez y Rita [1], sobre campañas telefónicas de un banco portugués. Contiene **45.211 clientes** y 17 variables: 16 predictoras y la variable objetivo *Subscription* (1 = se suscribe). Las predictoras se agrupan en perfil del cliente (edad, empleo, estado civil, educación), situación financiera (crédito en default, saldo promedio anual en euros, préstamos hipotecario y personal), campaña actual (medio, día y mes del último contacto, duración de la llamada y cantidad de llamadas) e historial (*Pdays*: días desde el contacto previo, con −1 = nunca contactado; *Previous*: contactos previos; *Poutcome*: resultado de la campaña anterior). El target está **fuertemente desbalanceado: solo el 11,7% se suscribe**.

No hay registros duplicados, pero sí valores faltantes en 9 columnas (11% y 17% de cada una), dispersos: el **71,7% de las filas tiene al menos un nulo**, por lo que eliminarlas no es viable. La tasa de suscripción cuando el dato falta (11,0%–12,8%) es igual a la general, lo que indica faltantes aleatorios y respalda una imputación simple. Además, *Pdays* = −1 coincide en el 100% de los casos con *Previous* = 0, regla utilizada para imputar *Pdays*.

Variable eliminada. La duración de la última llamada (*Last Contact Duration*) solo se conoce cuando la llamada terminó, al mismo tiempo que el resultado. Incluirla constituye *data leakage*: produciría métricas infladas en un modelo que no podría usarse para decidir a quién llamar, tal como advierten los propios autores del dataset [1].

3. Análisis exploratorio de datos

Para cada variable categórica se calculó la tasa de suscripción por categoría (Figura 1). **El historial con el banco es el factor más determinante**: quienes se suscribieron en la campaña anterior vuelven a hacerlo en el 64,7% de los casos, más de cinco veces la tasa general, mientras que los clientes nunca contactados (*unknown*) registran 9,2%. Los clientes endeudados se suscriben menos (7,7% con préstamo hipotecario frente a 16,7% sin él), y estudiantes y jubilados se ubican muy por encima de la media.

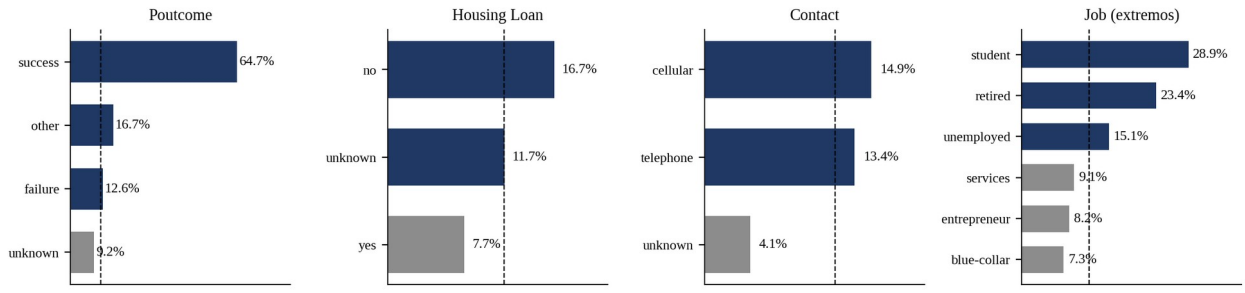


Figura 1. Tasa de suscripción por categoría (barras azules: superior a la tasa general; grises: inferior; línea punteada: 11,7%). Elaboración propia.

La tasa según el **mes de contacto** varía mucho, pero no por estacionalidad: en los meses de contacto masivo (mayo a julio) menos del 3% de los contactados tenía un éxito previo, mientras que en los meses con pocos contactos se seleccionó a clientes con historial exitoso. La tasa refleja la *selectividad* de la campaña.

Las variables continuas muestran poco poder discriminante por sí solas: la mayor correlación de Pearson con el target es 0,11 (*Pdays*) y el único par con correlación moderada es *Pdays–Previous* (0,46). *Balance*, *Campaign* y *Previous* son muy asimétricas (skewness 8,6; 4,9 y 41,9) y presentan valores extremos, que se conservaron por ser situaciones reales del negocio (saldos en descubierto, clientes contactados muchas veces). La baja correlación entre variables anticipó que PCA ofrecería poca compresión.

4. Materiales y métodos

Preprocesamiento. El dataset se dividió en entrenamiento (80%) y prueba (20%) de forma estratificada **antes** de imputar y escalar, para que ningún parámetro se aprendiera con datos de prueba. Imputación con parámetros de entrenamiento: moda en *Credit*, *Personal Loan* y *Marital Status*; mediana en *Age* y *Balance* (distribuciones asimétricas); categoría *unknown* en *Job*, *Education* y *Housing Loan* (esta última, equilibrada entre «sí» y «no»); y en *Pdays*, −1 si *Previous* = 0 y, en otro caso, la mediana de los clientes contactados. Se aplicó log(1 + x) a *Campaign* y *Previous*, y sign(x)·log(1 + |x|) a *Balance* (admite valores negativos); codificación one-hot con *drop_first* (evita la trampa de las variables ficticias) y estandarización z-score de las 6 variables numéricas. Resultado: 42 variables (6 numéricas y 36 dummies).

Modelos. Se compararon cuatro clasificadores: regresión logística (con regularización L1/L2), KNN, árbol de decisión y Random Forest [3], todos con *class_weight = balanced* salvo KNN, que no lo admite. Los hiperparámetros se eligieron con *GridSearchCV* y validación cruzada de 5 folds [4].

Métricas. La exactitud (*accuracy*) no es adecuada: un modelo que siempre predice «no suscribe» alcanza 88,3%. El criterio de selección fue el **AUC-ROC de validación cruzada** [2], independiente del umbral y del desbalance, que mide la calidad del ordenamiento de los clientes. Se reportan además precision, recall y F1 de la clase positiva.

Reducción de la dimensionalidad. Se aplicó PCA [5] dentro de un *Pipeline* (estandarización → PCA → modelo), de modo que en cada fold el PCA se ajusta solo con los datos de entrenamiento. La cantidad de componentes (25 o 30) se trató como hiperparámetro junto con los de cada modelo.

Umbral de decisión. Para el modelo elegido, el umbral se seleccionó maximizando F2 (que pondera el recall el doble que la precision) sobre probabilidades *out-of-fold* de entrenamiento, sin utilizar el conjunto de prueba, que se empleó una única vez para la evaluación final.

5. Experimentos y resultados

Tabla 1. Modelos con las 42 variables. Precision, recall y F1 de la clase «Suscribe» con umbral 0,5; «Llamadas»: % del conjunto de prueba clasificado como positivo.

Modelo	AUC CV	AUC test	Precision	Recall	F1	Llamadas
Regresión logística (C = 0,1; L1)	0,764	0,772	0,273	0,638	0,382	27,4%
KNN (k = 200, ponderado por distancia)	0,761	0,772	0,833	0,024	0,046	0,3%
Árbol de decisión (profundidad 10)	0,739	0,759	0,353	0,556	0,432	18,4%
Random Forest (200 árboles, profundidad 15)	**0,792**	**0,801**	**0,368**	**0,612**	**0,459**	**19,5%**

El **Random Forest** obtuvo el mejor AUC en validación cruzada y en prueba, unos 0,03 por encima del resto; el AUC de prueba acompaña al de validación en los cuatro modelos, sin señales de sobreajuste. Regresión logística y KNN tienen el mismo AUC en prueba (0,772) pero recalls de 63,8% y 2,4%: la diferencia proviene del umbral y de la escala de las probabilidades, no de la capacidad de ordenamiento. El primer corte del árbol es *Poutcome_success*, en línea con el análisis exploratorio.

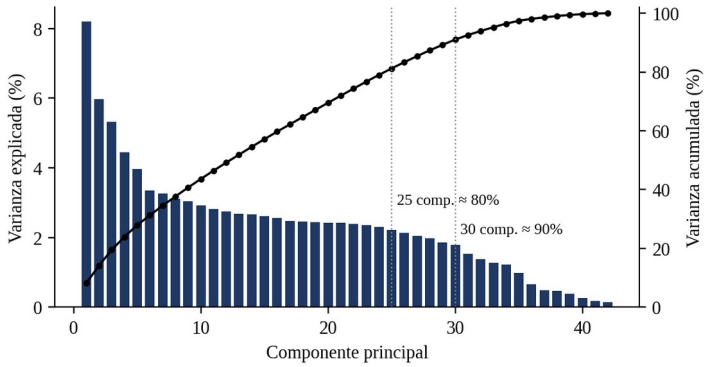


Figura 2. Varianza explicada por componente y acumulada (PCA sobre el conjunto de entrenamiento).

En PCA la varianza está muy repartida: la primera componente explica solo el 8,2%, y se requieren 25 componentes para el 80% y 30 para el 90% (Figura 2). La primera componente resume el historial de contacto (*Poutcome_unknown*, *Previous*, *Pdays*), pero en el plano de las dos primeras componentes suscriptores y no suscriptores aparecen superpuestos. Los cuatro modelos eligieron 30 componentes y **todos empeoraron** (Tabla 2).

Tabla 2. Efecto de PCA sobre el AUC (30 componentes en los cuatro casos).

Modelo	CV sin PCA	CV con PCA	Test sin PCA	Test con PCA
Regresión logística	0,764	0,744	0,772	0,754
KNN	0,761	0,752	0,772	0,763
Árbol de decisión	0,739	0,736	0,759	0,743
Random Forest	0,792	0,768	0,801	0,778

Con el Random Forest sin PCA, el umbral que maximiza F2 sobre las predicciones *out-of-fold* de entrenamiento (AUC 0,791) es **0,44** (Figura 3). En prueba, el recall sube de 61,2% a 69,6% (736 de los 1.058 suscriptores detectados, en lugar de 647) llamando al 28,8% de los clientes, con una precision de 28,3%. Los valores de entrenamiento y de prueba son consistentes, por lo que el umbral no quedó sobreajustado.

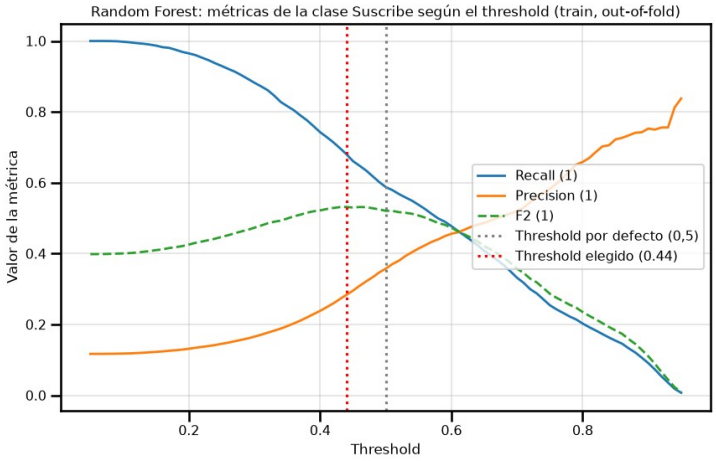


Figura 3. Precision, recall y F2 de la clase «Suscribe» según el umbral (Random Forest, entrenamiento out-of-fold).

6. Discusión y conclusiones

- **El historial con el banco explica la suscripción más que el perfil demográfico.** Haber suscrito antes es la señal más fuerte del dataset (64,7%), y el buen desempeño de los meses con pocos contactos se explica por la selección de esos clientes.
- **El Random Forest con las variables originales es el mejor modelo** (AUC 0,80). Al promediar árboles reduce la varianza de un árbol individual y captura interacciones no lineales que la regresión logística no modela.

- **PCA no aporta en este problema.** Las variables comparten poca información (baja correlación), por lo que no existe un subespacio pequeño que concentre la variabilidad; además, PCA maximiza la varianza sin usar el target y diluye variables clave como *Poutcome_success*. Con 42 variables tampoco hay un problema de costo computacional que justifique la pérdida de desempeño.
- **Recomendación al banco.** Usar el modelo como una lista de clientes ordenada por probabilidad. Con umbral 0,44 se alcanza el 69,6% de los suscriptores llamando al 28,8% de la cartera, 2,4 veces lo que se lograría llamando al azar a la misma cantidad de clientes. Las 846 llamadas adicionales respecto del umbral 0,5 suman 89 suscripciones (10,5%), por lo que bajar el umbral conviene si una suscripción vale más que unas diez llamadas; el umbral final debe fijarse con los costos reales.
- **Limitaciones y trabajo futuro.** El criterio F2 refleja un supuesto de costos y no costos reales; la imputación es simple; algunos hiperparámetros del Random Forest quedaron en el límite de la grilla; y podrían evaluarse modelos de boosting y selección de variables (Lasso) como alternativa a PCA.

Referencias

[1] Moro, S., Cortez, P. y Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. Decision Support Systems, 62, 22–31. https://doi.org/10.1016/j.dss.2014.03.001

[2] James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). An Introduction to Statistical Learning with Applications in Python. Springer.

[3] Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32.

[4] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[5] Jolliffe, I. T. y Cadima, J. (2016). Principal component analysis: a review and recent developments. Philosophical Transactions of the Royal Society A, 374(2065), 20150202.